Atividade Orientada 1 — Estatística sobre o meu próprio agente

D3 — Matemática e Estatística para IA · intervalo entre o primeiro sábado e a segunda sexta Cerca de 6 horas · **entrega até dois dias antes da segunda sexta, às 23h59**

A data exata desta turma está na tarefa do Moodle, onde você entrega.

O que você já tem, e o que falta

Você já tem	De onde veio
A medida de desempenho declarada, com definição operacional	Seção 4 do seu `agent-spec.md` (D2)
O agente de linha de base rodando, avaliado sobre ≥ 30 casos rotulados	Laboratório final da D2
O relatório de desempenho: a métrica, o valor, o conjunto	A entrega final da D2
Estatística descritiva com rigor sobre o seu dado, e a AED revisada	Laboratórios do primeiro sábado (D3)

O que falta é o que torna a pergunta "meu agente melhorou?" respondível: **um conjunto que aguente um teste**, **duas variantes** para comparar, e **a incerteza declarada** em torno de cada número.

Antes de começar: o que sessenta casos compram

A tarefa central desta atividade é ampliar o conjunto de avaliação de 30 para **pelo menos 60 casos rotulados**. Dito desde já, para não haver frustração mal interpretada: com 60 casos pareados, **só diferenças acima de dez a doze pontos percentuais se distinguem de acaso**. Ganhos de três a cinco pontos nesse volume serão indistinguíveis de ruído — e a resposta honesta do segundo sábado vai ser "não sei ainda" na maioria das entregas. **Isso é o que a matemática permite com esse tamanho de amostra, não fracasso do seu trabalho** — e reconhecer o limite da própria amostra é parte do que esta disciplina certifica.

O alerta que evita metade dos problemas: variantes tímidas

A segunda variante precisa **mudar comportamento, não um parâmetro cosmético**. Duas versões que diferem em quase nada produzem uma diferença real menor que o ruído da amostra — e o resultado será um "não sei" por **desenho ruim**, que não ensina nada. Exemplos do que conta como mudança de comportamento: trocar a regra de decisão, acrescentar um passo de verificação, mudar a fonte que o agente consulta primeiro. Mexer numa temperatura ou reescrever uma frase do prompt não é variante.

Os quatro itens da entrega

1. Ampliar o conjunto de avaliação de 30 para ≥ 60 casos rotulados

É trabalho braçal, e é a maior parte do esforço desta atividade — comece por ele. Cada caso é uma entrada real do seu domínio com o desfecho correto rotulado por você. Mantenha no repositório o arquivo do

conjunto no formato da D2 (uma linha por caso, com o desfecho esperado).

Avaliando as DUAS variantes sobre os MESMOS casos, produza o arquivo de acertos no formato que os laboratórios 05 e 06 leem — **uma linha por caso, uma coluna por variante, com 0 (errou) e 1 (acertou)**:

```
variante_a,variante_b
1,1
0,1
1,0
...
```

Os nomes das colunas são livres; os valores, não. Guarde como `acertos.csv` — é o arquivo que o laboratório do segundo sábado consome.

2. Notebook `notebooks/03-estatistica.ipynb`

Com as células executadas e as decisões escritas:

- **AED rigorosa do conjunto ampliado**: distribuições das variáveis relevantes, outliers **com a decisão justificada** (removeu? por quê? o que muda?), faltantes **com a hipótese de mecanismo** (MCAR, MAR, MNAR — e o que cada hipótese autoriza).
- **As duas variantes avaliadas sobre os mesmos 60 casos** — o pareamento é o que compra poder (o segundo sábado mostra a conta).
- ~~**Intervalo de confiança por reamostragem** para a métrica primária de cada variante, com o kit da disciplina (`comum/reamostragem.py`) e a **semente registrada** no notebook — sem semente, o número não é reproduzível.~~
- **Latência com p50 e p95** sobre as invocações do seu agente, e o parágrafo sobre por que a média é enganosa em distribuição de tempo de resposta.

~~3. Cálculo de tamanho de amostra, com a implicação escrita~~

Com o kit da disciplina (`comum/amostra.py` — a mesma função da demonstração "o que a amostra compra"; declare na chamada a taxa de base do SEU agente: ela é parâmetro do domínio e a função não tem valor padrão): quantos casos seriam necessários para detectar, com poder de 80% e significância de 5%, uma melhoria de **5 pontos percentuais**? Calcule nos dois desenhos (pareado e não pareado), e **escreva a implicação para o seu projeto**: o que a conta diz sobre o tamanho da melhoria que você pode honestamente procurar com o conjunto que tem — e o que faria valer a pena ampliar mais.

~~4. Uma página sobre correlação e causalidade no seu domínio~~

Identifique **uma correlação real nos seus dados** (duas variáveis que andam juntas) e liste **duas explicações não causais plausíveis** para ela: confundimento, viés de seleção, causalidade reversa — o que fizer sentido no seu caso. Uma correlação com uma só leitura é uma correlação mal examinada.

Critério de aceite

Os quatro itens existem no seu repositório: o conjunto com ≥ 60 casos rotulados e o `acertos.csv` das duas variantes; o notebook executado, com as decisões escritas e a semente registrada; o cálculo de tamanho de amostra com a implicação; a página de correlação e causalidade. O `conferir-entrega.py` do pacote de fechamento confere os itens da N2 — rode-o antes de entregar e conserte o que ele acusar.

Prazos, e por que o prazo é este

Entrega	Prazo	O que acontece
AO1	**até dois dias antes da segunda sexta, às 23h59**	Entra na devolutiva coletiva do E3, que comenta três entregas anonimizadas
AO1 em atraso	até uma semana depois do prazo da AO1	Devolutiva individual escrita, **sem perda de nota**

O prazo vence dois dias antes do segundo encontro porque a devolutiva coletiva comenta **três entregas anonimizadas** — sem entregas na véspera, aquela aula não existe. E o intervalo desta disciplina é de **três semanas, não duas**: a rotulagem é trabalho que não se faz na véspera — quem deixa para a última semana chega sem o material sobre o qual a segunda sexta trabalha.

Onde está cada coisa que você precisa

O que	Onde vem
O intervalo por reamostragem (as oito linhas do slide 19)	`comum/reamostragem.py`, no kit do pacote `D3-05` (Laboratório 05)
A conta de tamanho de amostra e poder	`comum/amostra.py`, no mesmo kit — a função `casos_para_diferenca`
O teste pareado das duas variantes	Laboratório do segundo sábado (`D3-06`); para a AO1 basta ter os acertos das duas variantes no formato acima
A AED com olhar crítico	O modelo do Laboratório 03 — as decisões de outlier e de faltante é que são novas aqui
O que sessenta casos compram, ao vivo	A demonstração "o que a amostra compra", no encontro da segunda sexta

---