

MAPA-DE-DATASETS — o dataset do seu domínio

Você precisa deste documento? Só se for pelo **caminho desafio**. Na AO1 há dois caminhos com a mesma nota: no **padrão**, você usa a manutenção AI4I do projeto exemplo (`python scripts/baixar-dados.py`) e não precisa de nada que está aqui; no **desafio**, você baixa os dados do SEU domínio, e é para isso que este mapa existe. O domínio que você escolheu no E1 vale nos dois — ele é a linha do projeto inteiro; o que muda é de onde vem a tabela. A tabela comparativa está no enunciado da AO1, seção "Dois caminhos, a mesma nota".

Você escolheu (ou vai escolher) um domínio na primeira aula. Este mapa diz **de onde vem o dataset** de cada domínio e **como baixar** dentro dos limites que a máquina de qualquer aluno aguenta:

Limite	Valor	O que acontece se passar
Download	≤ 200 MB	a receita recusa (nada é mantido) — escolha outro candidato
Memória	≤ 50.000 linhas	a receita gera uma amostra sistemática (mesma amostra em toda máquina, registrada no FONTE.md)
Piso do AO1	≥ 500 registros (ou ≥ 50 documentos)	a receita reclama se o resultado ficar abaixo
Corpus documental	≤ 200 documentos · ≤ 100 MB	vale para o domínio documental

Todo dataset da disciplina nasce do mesmo jeito, no formato que a D2–D7 esperam: `dados/dataset.csv` (ou `dados/documentos/`) + `dados/FONTE.md` com URL, data, licença, hash e contagem de linhas.

Como usar: na tabela abaixo, ache a linha do SEU domínio e rode a **receita pronta** (quando houver) direto da pasta `receitas/` deste pacote — `python receitas/baixar-dados-<dominio>.py` — e o `dados/` nasce na raiz do projeto. Prefere nome fixo? Copie a receita para a raiz como `baixar-dados.py` : funciona igual. Os candidatos sem receita ainda são baixados à mão. É isso que a AO1 cobra de quem vai pelo desafio. O **AI4I da manutenção é aceito** — ele é o dataset do caminho padrão, e vem pelo `scripts/baixar-dados.py` , não por uma receita daqui. O que a AO1 **não aceita** é dataset de exercício sem decisão por trás (Iris, Titanic e parecidos): eles não sustentam um `dominio.md` .

O que a sua escolha muda (leia antes de decidir)

O código do curso não muda — muda o DADO que atravessa tudo. O mesmo notebook e o mesmo cliente do modelo, com a receita do seu domínio no lugar do `scripts/baixar-dados.py` : o que você escolhe aqui define que tipo de dado o seu agente lê e que tipo de decisão ele automatiza até a defesa. Quem vai pelo caminho padrão faz essa troca mais tarde, quando quiser — o domínio escolhido continua sendo o dele desde o primeiro dia.

- **Domínios tabulares** (manutenção, suporte, crédito, logística, saúde): a matéria-prima é uma tabela → Pandas e NumPy desde o E2, e a **ferramenta preditiva da Aprendizado de Máquina (D5)** aprende com esses registros.
- **Domínios documentais** (jurídico/documental, compliance, triagem com textos): a matéria-prima é um **corpus de documentos** (≥ 50) → o caminho forte é a **busca com RAG na Engenharia de Prompt e IA Generativa (D9)**.
- **O que você adapta por domínio é UMA coisa:** a receita de download (URL e colunas). Todo o resto do curso é igual — e é por isso que a escolha é sua, não nossa.

Os 8 domínios e seus candidatos

Status: sondas e receitas executadas ao vivo em 27–28/08/2026 —  testado ao vivo (download/consulta feitos pela sonda ou pela receita) ·  download manual pelo navegador (login ou filtro no portal) ·  fonte a validar pela coordenação ·  atenção antes de usar. Requisito do Kaggle (domínios 2, 4, 6, 7 e 8): conta gratuita + token de API — a receita explica e também aceita o zip baixado à mão.

1. Manutenção industrial

 **Não use o AI4I 2020** — é o dataset do exemplo AMS da disciplina, e o AO1 não o aceita.

Receita pronta: `baixar-dados-manutencao.py` — `--conjunto hidraulico` (padrão) ou `--conjunto secom`; os dois testados ao vivo.

Candidato	Fonte	Registros	Tamanho	Status
Condition monitoring of hydraulic systems (UCI 447)	<code>archive.ics.uci.edu/static/public/447/...zip</code>	2.205 ciclos → tabela 22 colunas (5 alvos + média de 17 sensores)	zip 76,6 MB (a receita lê os perfis direto do zip — nada de 556 MB descompactados)	 receita pronta
SECOM (UCI 179)	<code>archive.ics.uci.edu/static/public/179/secom.zip</code>	1.567 × 592 (rótulo convertido para 1 = falhou)	zip 2 MB	 receita pronta

2. Suporte técnico de redes (chamados)

Receita pronta: `baixar-dados-suporte.py` (Kaggle, testada ao vivo).

Candidato	Fonte	Registros	Tamanho	Status
Telco Customer Churn (Kaggle)	<code>kaggle.com/datasets/blastchar/telco-customer-churn</code>	7.043 × 21	zip 175 KB	 receita pronta
Base de chamados do seu setor em dados abertos	validar com o professor	—	—	

3. Análise documental jurídica ou tributária (≥ 50 documentos)

Receita pronta: `baixar-dados-juridico.py` — **não precisa de conta:** a chave de API do DataJud é pública (o CNJ a publica no wiki) e já vem na receita. Testada ao vivo: 60 processos do TRF1 por assunto `contrato`, só sigilo 0, ~15 KB por processo.

Candidato	Fonte	Volume	Status
DataJud (CNJ) — API pública de processos	<code>api-publica.datajud.cnj.jus.br/api_publica_<tribunal>/_search</code> (POST)	60–200 processos por execução; paginação <code>search_after</code> testada	 receita pronta
Dados abertos do STF	<code>dadosabertos.stf.jus.br</code>	—	retirado em 28/08: HTTP 000 nas duas sondas; o DataJud cobre o domínio

4. Triagem de atendimento (FAQs e reclamações)

Receita pronta: `baixar-dados-triagem.py` (Kaggle, testada ao vivo).

Candidato	Fonte	Registros	Status
Customer Support Ticket Dataset (Kaggle)	<code>kaggle.com/datasets/suraj520/customer-support-ticket-dataset</code>	8.469 chamados × 17 colunas (CC0 — domínio público; a descrição tem texto livre para RAG)	✅ receita pronta
Consumer Complaint Database (CFPB, EUA) — use o filtro do portal para ~5 mil	<code>data.consumerfinance.gov</code>	milhões (filtrar)	👉 funciona no navegador (a API pública é que mudou de formato na sonda)

5. Compliance ambiental ou de segurança do trabalho

Este domínio tem DUAS naturezas — escolha a sua: o caminho **documental** (NRs, ≥ 50 documentos, forte para RAG na Engenharia de Prompt e IA Generativa) ou o caminho **tabular** (qualidade do ar, forte para a Aprendizagem de Máquina).

Candidato	Fonte	Registros	Status
Air Quality (UCI 360) — receita pronta (caminho tabular: monitoramento → alerta de limite)	<code>archive.ics.uci.edu/static/public/360/air+quality.zip</code>	9.357 horas × 15 sensores (valor -200 = sensor sem leitura)	✅ receita pronta
Normas Regulamentadoras (MTE/gov.br) — os PDFs públicos das NRs	buscar "normas regulamentadoras NR" no gov.br	~30+ documentos	👉 download manual (funciona no navegador; quem 404 na sonda foi a URL, não o portal)
Industrial Safety and Health Analytics (Kaggle) — acidentes numa mineradora	<code>kaggle.com/datasets/ihmstefanini/industrial-safety-and-health-analytics-database</code>	440 registros	⚠️ abaixo do piso de 500 do AO1 — só com liberação da coordenação
Licenciamentos ambientais em dados abertos (federal ou estadual)	validar com o professor	—	⌚

6. Crédito ou fraude

Receitas prontas: `baixar-dados-credito.py` (UCI 350, leve) e `baixar-dados-fraude.py` (Kaggle, testada ao vivo — zip de 150,8 MB, amostra sistemática para 50 mil linhas; o desequilíbrio das classes continua visível: 0,16% de fraudes na amostra).

Candidato	Fonte	Registros	Tamanho	Status
Default of Credit Card Clients (UCI 350) — receita pronta	archive.ics.uci.edu/static/public/350/default+of+credit+card+clients.zip	30.000 × 25	~5 MB	✅ testada
Credit Card Fraud Detection (Kaggle)	kaggle.com/datasets/mlg-ulb/creditcardfraud	284.807 × 31 → amostra de 50.000	zip 150,8 MB (dentro do teto de 200 MB)	✅ receita pronta

7. Logística (transporte)

Candidato	Fonte	Registros	Status
Bike Sharing (UCI 275) — atenção: é o dataset do exemplo rebike do AO1 ; só usar com liberação da coordenação	archive.ics.uci.edu/static/public/275/bike+sharing+dataset.zip	17.389 × 16	✅ ⚠️
DataCo Smart Supply Chain (Kaggle) — receita pronta (alvo: entrega atrasada)	kaggle.com/datasets/shashwatwork/dataco-smart-supply-chain-for-big-data-analysis	~180.000 × 53 → amostra de 50.000	✅ receita pronta (zip de 191 MB — passa raspando do teto de 200 MB; o guarda recusa se crescer)

8. Apoio administrativo em saúde (agendamento — jamais diagnóstico)

Receita pronta: [baixar-dados-saude.py](#) (Kaggle, testada ao vivo — 110.527 registros amostrados para 50.000, 1 a cada 2).

Candidato	Fonte	Registros	Status
Medical Appointment No Shows (Kaggle)	kaggle.com/datasets/joniarroba/noshowappointments	110.527 × 14 → amostra de 50.000 (licença CC BY-NC-SA 4.0 — não comercial, ok para o curso)	✅ receita pronta
Dados de agendamento em portais de saúde abertos	validar com o professor	—	⌚

A receita de download (os baixar-dados.py de cada domínio)

Cada receita é **autocontida**: rode-a direto de onde ela está, por exemplo `python receitas/baixar-dados-fraude.py`, ou copie-a para a raiz do repositório com o nome `baixar-dados.py` — nos dois casos o `dados/` nasce na raiz do projeto:

```
python receitas/baixar-dados-fraude.py          # baixa e converte
python receitas/baixar-dados-fraude.py --forçar  # refaz do zero
```

A receita faz TUDO: baixa respeitando o limite de disco, converte para `dados/dataset.csv` (ou `dados/documentos/` no jurídico), cria o `FONTE.md` (URL, data, licença, hash, contagem), aplica a amostra sistemática se passar de 50 mil linhas e reclama se o resultado cair abaixo do piso do AO1.

Domínio	Receita (na pasta receitas/ do D1-00)	Requisito extra
Manutenção	<code>baixar-dados-manutencao.py</code> (<code>--conjunto hidraulico</code> ou <code>secom</code>)	pandas
Suporte técnico	<code>baixar-dados-suporte.py</code>	pandas + token Kaggle
Jurídico/documental	<code>baixar-dados-juridico.py</code>	nada — só a biblioteca padrão (chave pública do CNJ já vem nela)
Triagem	<code>baixar-dados-triagem.py</code>	pandas + token Kaggle
Crédito (caso crédito)	<code>baixar-dados-credito.py</code>	pandas + <code>xlrd</code>
Crédito (caso fraude)	<code>baixar-dados-fraude.py</code>	pandas + token Kaggle
Saúde	<code>baixar-dados-saude.py</code>	pandas + token Kaggle
Logística	<code>baixar-dados-logistica.py</code>	pandas + token Kaggle
Compliance ambiental	<code>baixar-dados-compliance.py</code>	pandas + <code>openpyxl</code>

Sobre o token do Kaggle (domínios 2, 4, 6-fraude, 7 e 8): crie a conta gratuita, gere o token em `kaggle.com/settings` (seção API, começa com `KGAT_`) e **guarde-o no `.env` da raiz do projeto** — `KAGGLE_TOKEN=...`, na mesma linha dos segredos que a chave do Gemini. A receita lê de lá (e aceita também a variável de ambiente de mesmo nome ou o `~/.kaggle/kaggle.json` antigo). O `.env` está fora do Git — segredo não vai para o repositório.

Sem token? A receita também aceita o zip baixado **à mão** na página do dataset: salve como `dados/fonte.zip` e rode de novo — a conversão é igual.